

Soft Half-t 不等式约束模型说明

2026-06-05

1 目标

我们希望从一个候选阶段内的 feature 数据中判断该阶段是否存在单边不等式约束。给定一个阶段内的标准化 feature 样本

$$\mathcal{X} = \{x_1, \dots, x_n\},$$

不等式约束有两种方向：

$$\text{lower bound: } x \geq b, \quad \text{upper bound: } x \leq b.$$

模型的核心思想是：如果某个阶段确实满足单边不等式约束，那么样本应该集中在某个边界 b 的合法一侧，并且越靠近边界越常见；离边界越远，概率逐渐下降。同时，少量落在非法一侧的样本不应该导致 likelihood 直接变成零，因此使用 soft boundary 而不是 hard truncation。

2 方向和 signed slack

用一个方向变量 $d \in \{\text{lower}, \text{upper}\}$ 表示不等式方向。定义符号

$$a_d = \begin{cases} +1, & d = \text{lower}, \\ -1, & d = \text{upper}. \end{cases}$$

对任意样本 x_i ，定义 signed slack：

$$y_i = a_d(x_i - b).$$

于是：

- $y_i \geq 0$ 表示样本在合法一侧；
- $y_i = 0$ 表示样本正好在边界 b ；
- $y_i < 0$ 表示样本违反不等式约束。

lower bound 时， $y_i = x_i - b$ ；upper bound 时， $y_i = b - x_i$ 。

3 Soft Half-t Density

令 $t_\nu(z)$ 表示自由度为 ν 的标准 Student-t 密度:

$$t_\nu(z) = \frac{\Gamma(\frac{\nu+1}{2})}{\sqrt{\nu\pi}\Gamma(\frac{\nu}{2})} \left(1 + \frac{z^2}{\nu}\right)^{-\frac{\nu+1}{2}}.$$

Soft half-t 不等式模型定义为

$$p_{\text{ineq}}(x \mid b, \tau, \nu, \alpha, d) = \begin{cases} \frac{1}{Z} \frac{2}{\tau} t_\nu\left(\frac{y}{\tau}\right), & y \geq 0, \\ \frac{1}{Z} \frac{2}{\tau} t_\nu(0) \exp\left(\frac{y}{\alpha}\right), & y < 0, \end{cases}$$

其中

$$y = a_d(x - b).$$

归一化常数为

$$Z = 1 + \frac{2}{\tau} t_\nu(0) \alpha.$$

这个 density 可以理解为两部分:

- 合法侧 $y \geq 0$ 是 half-Student-t 分布;
- 非法侧 $y < 0$ 是指数泄漏项, 用来给 violation 一个连续但快速衰减的概率。

4 参数含义

模型参数包括

$$(b, \tau, \nu, \alpha, d).$$

各参数的含义如下:

- b : 不等式边界。lower bound 中是下界, upper bound 中是上界。
- d : 不等式方向, 决定合法区域在 b 的哪一侧。
- τ : 合法侧 half-t 的 scale, 控制合法侧数据离边界的典型距离。
- ν : Student-t 自由度, 控制尾部厚度。 ν 越小尾部越厚, 模型越能容忍远离边界的合法侧样本。
- α : soft boundary 的泄漏尺度, 控制非法侧 violation 的惩罚强度。

通常令

$$\alpha = \rho\tau,$$

其中 $\rho > 0$ 是相对 softness。 ρ 越小, 非法侧衰减越快, 模型越接近 hard inequality; ρ 越大, 非法侧越宽松。

5 模型形状

Soft half-t density 的最大值点在边界 b :

$$\arg \max_x p_{\text{ineq}}(x) = b.$$

在合法侧, density 从 b 开始随 $|x - b|$ 增大而下降:

$$p(x) \propto \left(1 + \frac{(a_d(x - b)/\tau)^2}{\nu}\right)^{-\frac{\nu+1}{2}}, \quad a_d(x - b) \geq 0.$$

在非法侧, density 从边界向外指数下降:

$$p(x) \propto \exp\left(\frac{a_d(x - b)}{\alpha}\right), \quad a_d(x - b) < 0.$$

因此, 这个分布是单峰、单边、边界锚定的。它不是对称分布, 也不会退化成普通 baseline 分布; 它始终表达“边界附近最高、合法侧 heavy tail、非法侧 soft penalty”的单边结构。

6 边界和 Scale 的估计

对于 lower bound, 边界通常由低分位数估计:

$$b_{\text{lower}} = Q_{q_b}(\mathcal{X}), \quad q_b \approx 0.05.$$

对于 upper bound, 边界通常由高分位数估计:

$$b_{\text{upper}} = Q_{1-q_b}(\mathcal{X}), \quad q_b \approx 0.05.$$

给定方向和边界后, 先计算合法 slack:

$$s_i = \max(a_d(x_i - b), 0).$$

scale τ 用 slack 的高分位数估计, 而不是用 second moment:

$$\tau_0 = \frac{Q_q(\{s_i\})}{T_\nu^{-1}\left(\frac{1+q}{2}\right)}, \quad q \in [0.9, 0.95].$$

其中 T_ν^{-1} 是标准 Student-t CDF 的 inverse。

这个公式来自 half-t 分布的 CDF:

$$P(S \leq s) = 2T_\nu(s/\tau) - 1.$$

所以

$$Q_q(S) = \tau T_\nu^{-1}\left(\frac{1+q}{2}\right).$$

使用高分位数估计 scale 的原因是: 当大量样本贴近边界时, 低分位数或 second moment 可能让 τ 过小, 使模型变成过尖的 spike; 高分位数可以让 scale 更多反映合法侧的整体 slack 宽度。

为了避免几乎常数的 feature 段产生无限尖锐的 density, 还可以设置观测噪声下限:

$$\tau = \max(\tau_0, \epsilon),$$

其中 ϵ 表示最小可辨别 feature 噪声尺度。

7 Likelihood

给定一个候选阶段的数据 $\mathcal{X}$, soft half-t 不等式模型的平均 negative log-likelihood 为

$$\text{NLL}_{\text{ineq}} = -\frac{1}{n} \sum_{i=1}^n \log p_{\text{ineq}}(x_i \mid b, \tau, \nu, \alpha, d).$$

如果需要比较 lower 和 upper 两个方向, 则分别计算

$$\text{NLL}_{\text{lower}}, \quad \text{NLL}_{\text{upper}},$$

并选择 likelihood 更好的方向:

$$\hat{d} = \arg \min_{d \in \{\text{lower}, \text{upper}\}} \text{NLL}_{\text{ineq}}(d).$$

8 Baseline Comparison

为了判断一个阶段是否真的表现出不等式结构, 需要和一个无约束 baseline 分布比较。baseline 的作用不是给分段提供奖励, 而是提供一个参照: 只有当单边不等式模型明显优于无约束模型时, 才认为该阶段存在不等式约束。

baseline 使用普通 Student-t 分布:

$$p_{\text{base}}(x \mid \mu_b, \sigma_b, \nu_b) = \frac{1}{\sigma_b} t_{\nu_b} \left(\frac{x - \mu_b}{\sigma_b} \right).$$

其平均 negative log-likelihood 为

$$\text{NLL}_{\text{base}} = -\frac{1}{n} \sum_{i=1}^n \log p_{\text{base}}(x_i \mid \mu_b, \sigma_b, \nu_b).$$

Student-t baseline 可以用稳健估计或 MLE 估计。概念上, baseline 应该描述“这个阶段的 feature 只是一个普通单峰无约束分布”的解释能力。它不包含边界 b , 也不区分 lower/upper 方向。

如果使用 MLE baseline, 可以固定自由度 ν_b , 优化

$$(\hat{\mu}_b, \hat{\sigma}_b) = \arg \min_{\mu, \sigma} \left[-\frac{1}{n} \sum_{i=1}^n \log p_{\text{base}}(x_i \mid \mu, \sigma, \nu_b) \right].$$

为了避免某些低方差阶段产生异常大的 likelihood, baseline scale 和 inequality scale 可以共享同一个最小噪声尺度:

$$\sigma_b \leftarrow \max(\sigma_b, \epsilon), \quad \tau \leftarrow \max(\tau, \epsilon).$$

这样做的含义是: feature 的测量或标准化后数值存在一个最小可分辨尺度, 任何模型都不应该把 scale 缩到低于这个尺度。

9 不等式方向选择

对于每个候选阶段和每个 feature, 可以分别拟合 lower-bound 和 upper-bound 两个 soft half-t 模型。

lower-bound 模型:

$$d = \text{lower}, \quad b_{\text{lower}} = Q_{q_b}(\mathcal{X}), \quad y_i = x_i - b_{\text{lower}}.$$

upper-bound 模型:

$$d = \text{upper}, \quad b_{\text{upper}} = Q_{1-q_b}(\mathcal{X}), \quad y_i = b_{\text{upper}} - x_i.$$

分别计算两个方向的不等式 NLL:

$$\text{NLL}_{\text{lower}} = -\frac{1}{n} \sum_i \log p_{\text{ineq}}(x_i \mid b_{\text{lower}}, \tau_{\text{lower}}, \nu, \alpha_{\text{lower}}, \text{lower}),$$

$$\text{NLL}_{\text{upper}} = -\frac{1}{n} \sum_i \log p_{\text{ineq}}(x_i \mid b_{\text{upper}}, \tau_{\text{upper}}, \nu, \alpha_{\text{upper}}, \text{upper}).$$

然后用相同的 baseline 作为参照, 得到两个方向的 gain:

$$\text{gain}_{\text{lower}} = \text{NLL}_{\text{base}} - \text{NLL}_{\text{lower}},$$

$$\text{gain}_{\text{upper}} = \text{NLL}_{\text{base}} - \text{NLL}_{\text{upper}}.$$

如果方向未知, 则选择 gain 最大的方向:

$$\hat{d} = \arg \max_{d \in \{\text{lower}, \text{upper}\}} \text{gain}_d.$$

等价地, 如果定义

$$\text{score}_d = \text{NLL}_{\text{ineq}, d} - \text{NLL}_{\text{base}},$$

则选择 score 最小的方向:

$$\hat{d} = \arg \min_{d \in \{\text{lower}, \text{upper}\}} \text{score}_d.$$

如果先验已经指定方向, 例如某个 feature 只能是 upper-bound 或只能是 lower-bound, 则不做方向搜索, 只评估指定方向。

10 激活判断

方向选定后, 判断该候选阶段是否激活不等式约束。设选定方向为 $\hat{d}$, 对应的不等式 NLL 为

$$\text{NLL}_{\text{ineq}} = \text{NLL}_{\text{ineq}, \hat{d}}.$$

定义 likelihood gain:

$$\text{gain} = \text{NLL}_{\text{base}} - \text{NLL}_{\text{ineq}}.$$

或者定义 score:

$$\text{score} = \text{NLL}_{\text{ineq}} - \text{NLL}_{\text{base}} = -\text{gain}.$$

激活规则为

$$\text{active} = \mathbf{1}[\text{gain} > \gamma],$$

其中 γ 是激活阈值。等价地, 若使用 score, 则

$$\text{active} = \mathbf{1}[\text{score} < -\gamma].$$

这个判断的意义是: 不等式模型必须比普通 Student-t baseline 好出一个 margin, 才认为该阶段真的存在单边约束。否则, 即使 soft half-t 本身能拟合数据, 也不把它当作有效约束。

11 分段中的 Likelihood / Cost

在分段时, 需要决定一个候选阶段是否因为满足不等式而获得约束项。这里区分两种情况。如果不等式没有激活:

$$\text{active} = 0, \quad C_{\text{ineq}} = 0.$$

也就是说, 未激活时不使用 baseline likelihood 影响分段。这样可以避免算法退化成“选择 baseline likelihood 最大的切分点”。baseline 只用于判断是否激活, 不作为 inactive segment 的分段目标。

如果不等式激活:

$$\text{active} = 1,$$

则使用 soft half-t 不等式模型的 total negative log-likelihood 作为该阶段的不等式代价:

$$C_{\text{ineq}} = \lambda_{\text{ineq}} \sum_{i=1}^n \left[-\log p_{\text{ineq}}(x_i \mid b, \tau, \nu, \alpha, \hat{d}) \right].$$

等价地, 使用平均 NLL 表示为

$$C_{\text{ineq}} = \lambda_{\text{ineq}} n \text{NLL}_{\text{ineq}}.$$

这里 n 是候选阶段长度, λ_{ineq} 是不等式约束项权重。使用 total NLL 的原因是: 分段目标应该考虑该阶段所有样本对约束的支持程度, 而不是只看平均值。长阶段中稳定满足约束比短阶段中的偶然贴边更有统计意义。

如果整个分段方案包含多个阶段和多个 feature, 则总不等式代价可以写成

$$C_{\text{ineq, total}} = \sum_k \sum_m \mathbf{1}[\text{active}_{k,m} = 1] \lambda_{\text{ineq}} \sum_{i \in \mathcal{S}_k} \left[-\log p_{\text{ineq}}(x_{i,m} \mid b_{k,m}, \tau_{k,m}, \nu, \alpha_{k,m}, d_{k,m}) \right],$$

其中 $\mathcal{S}_k$ 表示第 k 个阶段包含的时间点集合, m 表示 feature index。

12 整体流程总结

对每个候选阶段和每个 feature，方法流程如下：

1. 取该阶段内的标准化 feature 样本 $\mathcal{X}$ 。
2. 拟合无约束 Student-t baseline，得到 NLL_{base} 。
3. 拟合 lower soft half-t，得到 NLL_{lower} 和 $\text{gain}_{\text{lower}}$ 。
4. 拟合 upper soft half-t，得到 NLL_{upper} 和 $\text{gain}_{\text{upper}}$ 。
5. 如果方向未知，选择 gain 最大的方向；如果方向已知，只使用指定方向。
6. 若最佳 gain 超过激活阈值 γ ，则该 feature 在该阶段激活不等式约束。
7. 激活时，分段目标中加入 soft half-t total NLL；未激活时，该 feature 的不等式 cost 为 0。

13 直观解释

Soft half-t 不等式模型表达的是以下假设：

如果某个阶段存在单边约束，那么该阶段的 feature 应该在某个边界附近形成单峰密度；边界合法侧允许 heavy-tailed spread，非法侧允许少量 violation，但 violation 的概率随越界距离指数衰减。

这个模型相比 hard truncated distribution 更稳定，因为 violation 不会导致 likelihood 变成 $-\infty$ 。相比普通 Student-t baseline，它又保留了明确的单边 inductive bias：最高密度固定在边界上，而不是自由地把中心放在样本均值或中位数附近。

14 模型的主要优点和局限

优点：

- 明确表达 lower-bound 或 upper-bound 的单边结构。
- mode 锚定在边界 b ，适合描述“贴边”的不等式约束。
- 合法侧使用 Student-t heavy tail，对合法但远离边界的点较稳健。
- 非法侧使用 soft exponential leakage，可以容忍少量 violation。
- 通过和 baseline 比较，可以避免把所有阶段都强行解释成不等式约束。

局限：

- 如果一个多模态分布在某个方向上也能被解释成“边界附近高密度 + 合法侧 spread”，模型仍可能给出较高 likelihood。

- scale 太小时 likelihood 会异常尖锐，因此需要合理的 scale estimation 或 noise floor。
- 激活阈值控制模型的保守程度；阈值太低会漏检，太高会误检。
- 模型本身只描述单个 feature 的边缘分布，不直接建模多个 feature 之间的联合依赖。